

Metod Odkrywania Wiedzy

Sprawozdanie z projektu

Wojciech Klicki
Konrad Starzyk

15 listopada 2008

1 Zadanie

Zadanie składa się z dwóch części : implementacyjnej oraz badawczej. Część implementacyjna polega na implementacji metody dokonującej predykcji w środowisku GNU R. Na część drugą składa się szereg testów testujących skuteczność algorytmu.

Realizacja zadania polega na wykonaniu poniższych etapów:

- Postawienie pytań dotyczących danych wejściowych oraz algorytmu kooperatywnej filtracji, na które odpowiedź powinniśmy uzyskać przy pomocy Slope-One.
- Analiza danych – wybranie kategorii oraz atrybutów, które będą analizowane przez nasz algorytm.
- Implementacja algorytmu.
- Wykonanie eksperymentów, a następnie ocena jakości klasyfikatora.

2 Opis algorytmów

2.1 Kooperatywna filtracja

Kooperatywna filtracja polega na przewidywaniu ocen jakie otrzymają produkty od poszczególnych użytkowników na podstawie już ocenionych produktów. Zgadnięcie oceny polega na założeniu pewnego podobieństwa oceny jaką wystawi użytkownik do ocen już wystawionych.

2.2 Technika Slope-One

Przewidywanie preferencji za pomocą techniki Slope-One opiera się na założeniu, że ocenę użytkownika można przybliżyć za pomocą wzoru $f(x) = x + b$, który wyznacza średnią różnicę pomiędzy ocenami dwóch użytkowników którzy

dokonali oceny tego samego elementu. Jest to oczywiście daleko idące uproszczenie – w rozwinięciu tej techniki można korzystać z predyktorów o wzorach $f(x) = ax + b$ lub nawet $f(x) = ax^2 + bx + c$. Jak się jednak okazuje, nawet taki predyktor jest w stanie trafnie przewidywać preferencje użytkowników.

Oznaczmy przez v_i i w_i tablice ocen dla dwóch różnych użytkowników, gdzie $i = 1..n$ jest indeksem przedmiotu. Wtedy $v_i - w_i$ jest różnicą ocen tego samego przedmiotu przez dwóch użytkowników. Spróbujmy znaleźć wartość która najlepiej przybliży różnicę w ocenach dawanych przez tych użytkowników.

Minimalizując wyrażenie: $\sum_i (v_i + b - w_i)^2$ ze względu na parametr b otrzymujemy $b = \frac{\sum_i v_i - w_i}{n}$.

Mając zbiór testowy κ oraz dowolne dwa oceniane przedmioty i oraz j , wraz z ich ocenami u_i oraz u_j możemy określić średnie odchylenie przedmiotu i względem j jako:

$$dev_{i,j} = \sum_{u \in S} \frac{u_j - u_i}{|S|}$$

gdzie jako S oznaczmy zbiór ocen które zawierały obydwa przedmioty.

Biorąc pod uwagę, że nieznaną wartość oceny przedmiotu j możemy przewidywać jako $u_j = dev_{i,j} + u_i$, sensowny predyktor mógłby być średnią takich przewidywań:

$$P(u)_j = \frac{1}{|R_j|} \sum_{i \in R_j} (dev_{i,j} + u_i)$$

gdzie R_j jest zbiorem wszystkich przedmiotów i które zostały ocenione i dla których istnieje wyznaczona wartość średniego odchylenia względem przedmiotu j równa $dev_{i,j}$.

3 Plan eksperymentów

3.1 Pytania

- Jaka będzie przewidywana ocena danego filmu przez danego użytkownika wyznaczona przez algorytm?
- Jaka będzie trafność tej oceny?

3.2 Charakterystyka zbiorów danych

Dane używane do testów pochodzą z serwisu Movielens. Dostępne są dwa zestawy danych: pierwszy składa się z 100,000 ocen 1682 filmów wystawionych przez 943 użytkowników. Drugi zawiera około miliona ocen 3900 filmów wystawionych przez 600 użytkowników. Każdy film został oceniony w skali od 1 do 5.

coś tu jeszcze dodać? jak dzielimy zbiór testowy??

3.3 Parametry algorytmów których wpływ na wyniki będzie badany

Algorytm nie zawiera parametrów którymi można sterować jego działaniem.

3.4 Sposób oceny jakości modeli

Aby ocenić trafność przewidywań porównamy je z danymi ze zbioru testowego. Każdą wyznaczoną ocenę \hat{u}_j porównujemy z oceną testową u_j . Ponieważ istnieje 5 możliwych ocen, błąd dla jednej oceny możemy określić jako:

$$e_j = \frac{|\hat{u}_j - u_j|}{5}$$

gdzie $j = 1..n$, a n to liczba wszystkich przewidywań. Średni błąd będzie więc równy:

$$\sum_j \frac{|\hat{u}_j - u_j|}{5n}$$

Stąd miarę jakości oceny możemy wyrazić jako:

$$q = 1 - \sum_j \frac{|\hat{u}_j - u_j|}{5n}$$

4 Otwarte kwestie wymagające późniejszego rozpatrzenia